

Unicode

Unicode ist ein Standard, in dem langfristig für jedes sinntragende Schriftzeichen oder Textelement ein Code festgelegt wird.
ISO 10646 ist die ISO-Kennzeichnung für den Unicode-Zeichensatz. Er wird dort als Universal Character Set (**UCS**) bezeichnet.



Die **ersten 256 Zeichen** des Unicode entsprechen der ISO 8859-1-Kodierung (**Latin1**).

Der Unicode ist in **17 Ebenen (planes)** gegliedert, die **je 65.536 Zeichen** umfassen. Die Anzahl 17 ergibt sich daraus, dass im UTF-16-Format genau 17 Planes dargestellt werden können. Sechs dieser Planes werden bereits verwendet:

- Die **Basic Multilingual Plane (BMP; Mehrsprachige Basis-Ebene, Plane 0)** enthält Schriftsysteme, die aktuell in Gebrauch sind, Satzzeichen, Symbole, Kontrollzeichen, Surrogate-Paare, und einen privat nutzbaren Bereich (**PUA**).
- Die **Supplementary Multilingual Plane (SMP; Ergänzende mehrsprachige Ebene, Plane 1)** bezeichnet) enthält vor allem historische Schriftsysteme.
- Die **Supplementary Ideographic Plane (SIP; Ergänzende ideographische Ebene, Plane 2)**, enthält ausschließlich selten benutzte CJK-Zeichen (China-Japan-Korea).
- Die **Supplementary Special-purpose Plane (SSP; Ergänzende Ebene für spezielle Verwendungen, Plane 14)** enthält u. a. Codes für HTML-Zeichen, wie z. B. <, > und ".
- Die letzten beiden Ebenen, **Supplementary Private Use Area-A und -B (PUA; Plane 15 und Plane 16)**, stehen als privat nutzbare Bereiche (**PUA**) zur Verfügung.

00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F	
10	11	12	13	14	15	16	17	18	19	1A	1B	1C	1D	1E	1F	
20	21	22	23	24	25	26	27	28	29	2A	2B	2C	2D	2E	2F	
30	31	32	33	34	35	36	37	38	39	3A	3B	3C	3D	3E	3F	
40	41	42	43	44	45	46	47	48	49	4A	4B	4C	4D	4E	4F	
50	51	52	53	54	55	56	57	58	59	5A	5B	5C	5D	5E	5F	
60	61	62	63	64	65	66	67	68	69	6A	6B	6C	6D	6E	6F	
70	71	72	73	74	75	76	77	78	79	7A	7B	7C	7D	7E	7F	
80	81	82	83	84	85	86	87	88	89	8A	8B	8C	8D	8E	8F	
90	91	92	93	94	95	96	97	98	99	9A	9B	9C	9D	9E	9F	
A0	A1	A2	A3	A4	A5	A6	A7	A8	A9	AA	AB	AC	AD	AE	AF	
B0	B1	B2	B3	B4	B5	B6	B7	B8	B9	BA	BB	BC	BD	BE	BF	
C0	C1	C2	C3	C4	C5	C6	C7	C8	C9	CA	CB	CC	CD	CE	CF	
D0	D1	D2	D3	D4	D5	D6	D7	D8	D9	DA	DB	DC	DD	DE	DF	
E0	E1	E2	E3	E4	E5	E6	E7	E8	E9	EA	EB	EC	ED	EE	EF	
F0	F1	F2	F3	F4	F5	F6	F7	F8	F9	FA	FB	FC	FD	FE	FF	

Lateinische Schriften und Symbole

Lautechriften

Andere europäische Schriften

Nahost- und Südwestasiatische Schriften

Afrikanische Schriften

Südasiatische Schriften

Südostasiatische Schriften

Ostasiatische Schriften

CJK-Ideogramme

Kanadische Silben

Symbole

Diakritika

UTF-16-Surrogates und privater Nutzungsbereich

Verschiedene Zeichen

Nicht belegte Codebereiche

Basic Multilingual Plane

Jedem Zeichen ist eine **Nummer** zugeordnet. Diese Nummer wird auch als **Codepunkt** bezeichnet. Sie wird hexadezimal (mindestens vierstellig) und mit einem vorangestellten U+ dargestellt, z. B. U+00DF für das ß. Zusätzlich gibt es einige Codepunkte, die kein Zeichen darstellen sondern für andere Zwecke benötigt werden.

Es gibt insgesamt 1.114.112 Codepunkte (**U+0000 ... U+10FFFF**). Die folgenden Codepunkte stellen keine Zeichen dar:

- 2048 Codepunkte im Bereich U+D800 ... U+DFFF werden als **Teile von Surrogate-Paaren (Ersatz-Paaren)** im Kodierungsschema UTF-16 zur Darstellung von Codepunkten oberhalb der BMP (also im Bereich U+10000 ... U+10FFFF) verwendet.
- 66 Codepunkte, 32 im Bereich U+FDD0 ... U+FDEF sowie je 2 am Ende jeder der 17 Ebenen (also U+FFFE, U+FFFF, U+1FFFE, U+1FFFF, ..., U+10FFFE ... U+10FFFF) sind für *process-internal uses* reserviert.

Kodierungskriterien

Unicode-basierte Systeme sollten herkömmlich kodierte Daten mit geringem Aufwand handhaben können. Dazu wurden für die unteren 256 Zeichen die ISO 8859-1-Kodierung (Latin1) ebenso wie die Kodierungsarten verschiedener nationaler Normen beibehalten.

Es gibt viele Unicode-Zeichen, denen keine **Glyphe** (grafische Darstellung) zugeordnet ist, z. B. Tabulator (U+0009), Zeilenvorschub (U+000A) und 19 verschiedene Codes für das Leerzeichen.

Darstellung auf dem Computer

HTML und XML unterstützen Unicode. Die Notation lautet **�** für dezimale Notation bzw. **�** für hexadezimale Notation.

In Microsoft Word kann Unicode hexadezimal eingegeben werden, indem im Dokument die **Unicode-Nummer** oder **U+** und die Unicode-Nummer eingetippt wird und anschließend **[Alt]+[C]** im Dokument bzw. **[Alt]+[X]** in Dialogfeldern. Diese Tastenkombination kann auch benutzt werden, um den Code des vor dem Cursor stehenden Zeichens anzuzeigen.

In Windows ist es mit dem Programm **charmap** möglich, Unicode-Zeichen einzufügen.

Ob das entsprechende Unicode-Zeichen tatsächlich am Bildschirm erscheint, hängt davon ab, ob die verwendete **Schriftart** eine Glyphe für das gewünschte Zeichen enthält.

Der Coderaum von Unicode hat einen Umfang angenommen (mehr als 100.000 Schriftzeichen), der sich nicht mehr in einer Schriftdatei unterbringen lässt. Die gängigsten Schriftdateiformate, **TrueType** und **OpenType**, können maximal 65.536 Zeichen enthalten. Ägyptische Hieroglyphen z. B. sind in den obigen Zeichensätzen nicht enthalten. Dafür gibt es spezielle Zeichensätze. Rechts das Zeichen **U+13068** aus der **SMP**:



Bei Windows-Systemen befinden sich die Zeichensätze im Ordner C:\Windows\Fonts.