

UTF-16

UTF-16 (englisch für *Universal Multiple-Octet Coded Character Set (UCS) Transformation Format for 16 Planes of Group 00*) ist die älteste Kodierung für Unicode-Zeichen.

Bei der UTF-16-Kodierung wird jedem Unicode-Zeichen eine Bytekette von **zwei** oder **vier Byte** Länge zugeordnet.

Während UTF-8 eine zentrale Bedeutung in Internet-Protokollen hat, wird UTF-16 vielerorts zur internen Zeichenkettenrepräsentation verwendet, beispielsweise in Java.

Kodierung

Die Zeichen der **BMP** (Basic Multilingual Plane, U+0000 bis U+FFFF) werden direkt auf die 16 Bits einer UTF-16-Code-Unit abgebildet.

Unicode-Zeichen **außerhalb der BMP** (d. h. U+10000 bis U+10FFFF) werden durch zwei 16-Bit-Wörter (engl. *code units*) dargestellt, die wie folgt gebildet werden:

Von der Nummer des Zeichens wird zunächst die Zahl 65536_{dez} (= **10000**_{hex}) abgezogen. Das ist genau die Größe der BMP. Dadurch entsteht eine 20-Bit-Zahl im Bereich von 00000_{hex} bis FFFFF_{hex}. Diese wird in zwei Blöcke zu je 10 Bit aufgeteilt. Dem ersten Block wird **110110**, dem zweiten Block **110111** vorangestellt.

Das erste der beiden 16-Bit-Wörter bezeichnet man als *High-Surrogate*, das zweite als *Low-Surrogate*. Die Unicode-Bereiche von U+D800 bis U+DBFF und von U+DC00 bis U+DFFF sind für diese UTF-16-Ersatzzeichen reserviert.

Byte Order

Je nachdem, welches der beiden Bytes zuerst übertragen bzw. gespeichert wird, spricht man von *Big Endian* (UTF-16BE) oder *Little Endian* (UTF-16LE).

Oft wird das Unicode-Zeichen U+FEFF (BOM, *byte order mark*), das ist ein Leerzeichen mit Breite Null und ohne Zeilenumbruch (*zero width no-break space*), an den Anfang der Daten gesetzt. Wird es als das ungültige Unicode-Zeichen U+FFFE (*not a character*) interpretiert, muss die Byte-Reihenfolge beim Empfänger vertauscht werden.

Beispiele für UTF-16 Kodierungen

Zeichen	Unicode	Unicode binär	UTF-16 binär	UTF-16 hexadezimal
Buchstabe y	U+0079	00000000 0 <u>1111001</u>	00000000 0 <u>1111001</u>	00 79
Buchstabe ä	U+00E4	00000000 <u>11100100</u>	00000000 <u>11100100</u>	00 E4
Eurozeichen €	U+20AC	00 <u>100000</u> <u>10101100</u>	00 <u>100000</u> <u>10101100</u>	20 AC
Violinschlüssel ♪	U+1D11E	0000 <u>0001</u> <u>11010001</u> <u>00011110</u>	<u>11011000</u> <u>00110100</u> <u>11011101</u> <u>00011110</u>	D8 34 DD 1E
CJK-Ideogramm 𐤎	U+24F5C	0000 <u>0010</u> <u>01001111</u> <u>01011100</u>	<u>11011000</u> <u>01010011</u> <u>11011111</u> <u>01011100</u>	D8 53 DF 5C

Unterstrichen sind jeweils die binären Unicode-Ziffern ohne führende Nullen.