

UTF-8

UTF-8 (*8-Bit Universal Character Set Transformation Format*) ordnet jedem Unicode-Zeichen eine Zeichenkette zwischen einem und vier Bytes zu.

Die im europäisch/englischen Sprachraum meistbenutzten Zeichen sind die **Unicode**-Zeichen mit den Werten aus dem Bereich von **0 bis 127** (= 7-bit-ASCII-Zeichen) werden **unverändert** als **ein Byte** dargestellt.

Unicode-Zeichen größer als 127 werden umgerechnet und als Byteketten in einer der Länge von **zwei**, **drei** oder **vier Bytes** dargestellt.

- Ist das höchste bit eines UTF-8-Bytes **0**, handelt es sich um ein Ein-Byte-Zeichen. Es ist dann identisch mit dem **7-bit-ASCII-Code**.
- Ist das erste bit eines UTF-8-Bytes eine **1**, handelt es sich um ein Byte eines **Mehrbytezeichens**.
- Sind die ersten bits eines UTF-8-Bytes **11** oder **111** oder **1111**, handelt es sich um das **Startbyte** eines Mehrbytezeichens.
- Lauten die ersten bits eines UTF-8-Bytes **10**, handelt es sich um ein **Folgebyte** eines Mehrbytezeichens.
- Bei den Startbytes von Mehrbyte-Zeichen gibt die Anzahl der ersten 1-bits vor der ersten 0 die Anzahl der Bytes des Zeichens an.
- Die Binärform der Unicode-Nr. wird dann **rechtsbündig** in die unten dargestellten x-Positionen übernommen und links ggf. durch Nullen aufgefüllt.

Unicode (hex)		UTF-8	UTF-8-Kodierung (binär)
von	bis		
00 00 00 00	00 00 00 7F	Ein-Byte-Zeichen	0xxxxxxx
00 00 00 80	00 00 07 FF	Zwei -Byte-Zeichen	11 0xxxxx 10 xxxxxx
00 00 08 00	00 00 FF FF	Drei -Byte-Zeichen	111 0xxxx 10 xxxxxx 10 xxxxxx
00 01 00 00	00 10 FF FF	Vier -Byte-Zeichen	1111 0xxx 10 xxxxxx 10 xxxxxx 10 xxxxxx

Beispiele für UTF-8 Kodierungen

Zeichen	Unicode	Unicode binär	UTF-8 binär	UTF-8 hexadezimal
Buchstabe y	U+0079	00000000 01111001	01111001	79
Buchstabe ä	U+00E4	00000000 11100100	11 000011 10 100100	C3 A4
Eurozeichen €	U+20AC	00100000 10101100	111 00010 10 000010 10 101100	E2 82 AC
Violinschlüssel ♪	U+1D11E	00000001 11010001 00011110	1111 0000 10 011101 10 000100 10 011110	F0 9D 84 9E